

AGOPD: 优势门控在线蒸馏——缓解小模型数学推理中的教师监督负迁移

AGOPD: Advantage-Gated On-Policy Distillation for Mitigating Negative Transfer in Small-Model Mathematical Reasoning

AGOPD-RL Research Group

Independent empirical study • working paper

Student Qwen3-1.7B Base Teacher Qwen3-4B-GRPO Data DAPO-Math-17K

Main Eval 1,024 prompts • paired

摘要

在线策略蒸馏（on-policy distillation, OPD）能够在学生模型自生成轨迹上提供密集的词元级教师监督，但该监督的价值取决于教师所面对的学生状态。本文以未经后训练的 Qwen3-1.7B Base 和 DAPO-Math 为研究对象，考察 OPD 与基于结果奖励的强化学习联合训练时的负迁移现象。在统一的非思考解码协议下，对 16,164 道训练题逐题进行 $n = 8$ 采样，以八次采样中正确回答的次数估计逐题能力；其中 48.9% 的题目八次采样均未得到正确答案（95% CI [48.1%, 49.7%]），其余题目的成功率在整个 0/8–8/8 区间上分布跨度较大。在共享训练数据、训练预算和评估协议的条件下，GRPO 基线在固定 1,024 题上的准确率为 28.42%；无条件加入 OPD 后下降至 24.12%，较 GRPO 下降 4.30 个百分点（配对 bootstrap 95% CI [-6.93, -1.66]）。正确的 chat-template 重测显示，固定教师在五个学生能力区间均保持正向的题目级结果优势；与此相对，状态干预实验显示教师救援率随错误前缀加深而下降，长度匹配控制进一步表明该损伤主要来自错误推理语义而非上下文长度。基于上述区分，本文提出优势门控在线策略蒸馏（Advantage-Gated On-Policy Distillation, AGOPD）：仅对组相对优势为负的学生轨迹启用候选蒸馏，并要求教师模型独立求解同一问题且通过相同结果验证器。AGOPD 的准确率达到 27.05%，较无门控 RL+OPD 提升 2.93 个百分点（95% CI [+0.29, +5.57]）；其与 GRPO 的剩余差异在当前配对评估中未达到统计显著性。上述结果表明，教师监督的作用域必须同时考虑结果级能力与状态级可恢复性。

关键词：在线策略蒸馏；强化学习；GRPO；数学推理；条件教师优势；负迁移；小语言模型

Abstract. On-policy distillation (OPD) provides dense token-level supervision on trajectories generated by the student policy, but its value depends on the states visited

by the student. We study this issue with the unpost-trained Qwen3-1.7B Base on DAPO-Math. Under a standardized non-thinking protocol, an $n = 8$ capability census over 16,164 training prompts finds that 48.9% of prompts receive zero correct samples (95% CI [48.1%, 49.7%]); the remaining prompts are broadly spread across success counts 1–8. Under matched training data, optimization budget, and evaluation protocol, a GRPO baseline achieves 28.42% accuracy on a fixed 1,024-prompt evaluation, whereas adding unconditional OPD reduces accuracy to 24.12%, a decrease of 4.30 percentage points (paired-bootstrap 95% CI [−6.93, −1.66]). Corrected chat-template evaluation shows a positive teacher advantage across all five student-competence bins, whereas state-intervention experiments show progressively lower teacher rescue after deeper erroneous student prefixes; length-matched controls attribute most of the degradation to erroneous reasoning semantics rather than context length alone. Motivated by this distinction, we propose Advantage-Gated On-Policy Distillation (AGOPD), which restricts candidate distillation to negative-advantage student trajectories and further requires the teacher to independently solve the prompt under the same outcome verifier. AGOPD reaches 27.05%, recovering 2.93 percentage points over unconditional RL+OPD (95% CI [+0.29, +5.57]); its remaining gap to GRPO is not statistically significant on the paired evaluation. These results support conditioning teacher supervision on both outcome-level competence and state-level recoverability.

48.9% 标准化 n=8 普查中 0/8 成功的训练 题目	−4.30pp 无条件 RL+OPD 相对 GRPO 的显著下降
+2.93pp AGOPD 相对 RL+OPD 的显著恢复	40.2% 主训练中平均被 负优势门 激活的 轨迹 rows

1

引言

可验证结果奖励已成为数学推理后训练的重要监督来源。以 GRPO 与 DAPO 为代表的方法，通过对同一问题多次采样并做组内相对比较，在不依赖独立价值模型的条件下构造策略优化信号 [1][2]。在线策略蒸馏（on-policy distillation, OPD）则在学生模型实际访问的状态上引入教师分布监督，以缓解离线蒸馏中的状态分布偏移 [4]。两类目标分别提供**结果级监督**与**词元级**

监督：结果奖励对整条回答给出可验证的正确性信号，词元级教师分布则对每个前缀位置给出条件分布目标。前者稀疏但可信，且随任务可无限扩展；后者密集，但由固定教师模型提供，其正确性不随学生状态自动成立。因此，将两者联合训练的收益需要以受控实验验证，而非先验假定。

然而，联合训练的有效性依赖于一个隐含前提——**教师模型在学生访问的状态上具有教学价值**。为检验该前提，本文在未经后训练的 Qwen3-1.7B Base 与 DAPO-Math-17K 上进行受控实验：四种方法共享训练子集、优化配置与固定评估协议，仅在是否叠加教师监督上不同。结果表明，无条件联合 OPD 与结果监督强化学习（RL+OPD）会造成显著性能下降：GRPO 在固定 1,024 道验证题上的准确率为 28.42%，RL+OPD 仅为 24.12%，逐题配对统计给出 -4.30 个百分点（95% bootstrap 置信区间 $[-6.93, -1.66]$ ，McNemar 精确检验 $p=0.0018$ ）。换言之，在学生已能形成有效策略更新的状态下，无条件教师监督可能干扰而非促进学习。

负迁移不能由教师的题目级能力单独解释。重新校准后，教师从题目根状态作答时在不同学生能力区间均保持稳定优势；然而，当教师继续处理学生已经偏离正确路径的推理状态时，其可恢复性随错误路径加深而持续下降。长度匹配控制进一步表明，这种退化主要与错误推理所携带的语义状态有关，而不是上下文变长本身。由此，本文将分析重点从“教师是否更强”转向“教师监督在什么状态上仍然可靠”。

基于上述区分，本文提出**优势门控在线策略蒸馏**（Advantage-Gated On-Policy Distillation, AGOPD）。其设计直接复用联合强化学习过程中已计算的组相对优势：仅将负优势学生轨迹视为蒸馏候选；随后要求固定教师模型独立求解同一问题，并通过与学生模型一致的结果验证器。只有同时满足学生侧负优势条件与教师侧可验证正确条件时，教师词元级目标才被施加于对应学生访问状态。该设计不改变基础 GRPO 优势估计器，也不训练额外路由模型，而是把蒸馏目标的非零作用域限制在结果级可验证性与轨迹级相对劣势的交集上。

本文的主要贡献如下：

- **受控负迁移测量。**在固定 1,024 题的逐题配对评估中，无条件叠加教师词元监督带来可测量的逐题性能下降，把负迁移从经验现象变成可检验的统计结论（配对统计见表 4）。
- **题目级与状态级诊断。**正确协议下的能力分层显示固定教师在各区间均保持非负结果优势；反事实错误前缀实验进一步表明，题目级教师能力不能保证状态级救援可靠性。
- **优势门控蒸馏。**AGOPD 将组相对优势与可验证教师正确性组合为两级路由条件，在无门控 RL+OPD 基础上带来可测量的恢复，并明确限定其适用范围与统计边界。
- **学习层面的机制验证。**在训练预算与评估协议严格对齐的对照中，以语义正确率衡量（最终答案与参考答案数学等价即计为正确，不苛求输出格式），从题目根状态学习完整可验证正确轨迹的序列级监督呈现优于在学生访问前缀上施加教师词元分布的方向；统计不确定性仍覆盖零差异，该结果仅作为状态错位解释的学习层支持，而非独立的显著性结论。

据此，本文提出四项可检验的研究主张（命题 1-4）：(1) 在稳定 GRPO 基线上无条件叠加 OPD 会造成可测量的逐题性能下降；(2) 题目级教师优势不能充分预测其在学生访问状态上的监督可靠性；(3) 以组相对优势与可验证教师正确性构成的双重门控能够缓解上述负迁移；(4) AGOPD 的作用在于限制蒸馏目标的作用域，其适用性仍受学生训练阶段与教师能力边界约束。第 3、5 章将按这些主张组织证据。

2

任务、数据与基础方法

2.1 任务与数据构造

本文研究数学推理的结果监督强化学习：给定竞赛数学题 x ，学生模型需生成以 **Answer:** 结尾的答案，由规则验证器判定对错。训练题来自 DAPO-Math-17K，清洗后共 16,164 道；固定验证集 1,024 道用于所有方法比较（协议见 § 5.1 与表 3）。

数据对象按用途分为三类。第一，16,164 道清洗后的训练题用于标准化能力普查，以估计基础学生的逐题成功率 $\hat{p}(x)$ 并诊断组内结果监督的信号密度；其离散分布见表 A1。第二，主四臂实验使用一个固定的 1,472 题训练池，四种方法共享该训练池、优化配置与随机种子，从而将方法差异限定为教师监督及其路由方式。第三，困难桶实验使用 1,120 道 $\hat{p} = 0.125$ 的题目和随机抽取的 2,000 道 $\hat{p} = 0$ 题目，共 3,120 道，用于检验低学生成功率区域的训练边界。1,472 题训练池来自早期前沿筛选流程，并非标准化普查的直接阈值切片；这一来源差异及其影响在附录 A 中单独说明。

2.2 结果监督下的组相对强化学习

给定数学问题 x ，当前学生策略 π_θ 对同一问题采样 G 条响应 $y_i \sim \pi_\theta(\cdot | x)$ 。结果验证器返回奖励 $r_i = V(x, y_i)$ 。本文主实验使用二值正确性奖励，并在同一问题的采样组内计算标准化相对优势：

$$A_i = \frac{r_i - \mu_r}{\sigma_r + \epsilon}, \quad \mu_r = \frac{1}{G} \sum_{j=1}^G r_j \quad (1)$$

式 (1) 中的 A_i 描述第 i 条轨迹相对于同一问题其他采样轨迹的表现，而非问题的绝对难度。这一组内相对化正是 GRPO 省去显式 critic 的设计依据：以同题多次采样作为基线，避免了在每个状态上训练价值网络的存储与稳定性开销。对于二值奖励，只有组内同时出现成功与失败时才形成正负对比；若组内奖励完全一致，则标准化后的组相对信号退化。

2.3 有效组率与训练信号密度

设某题在当前策略下的单次成功概率为 p 。对于大小为 G 的独立采样组，组内至少包含一条成功轨迹和一条失败轨迹的概率定义为有效组率（Effective Group Rate, EGR）：

$$\text{EGR}(p, G) = 1 - (1 - p)^G - p^G \quad (2)$$

由式 (2) 可知，当 $p \rightarrow 0$ 或 $p \rightarrow 1$ 时，EGR 均趋近于 0。因此，数据集平均准确率并不能直接反映组相对强化学习的有效信号密度。本文仅将 EGR 作为训练信号诊断量，而不将其作为 AGOPD 的门控规则。

2.4 在线策略蒸馏

在线策略蒸馏在学生模型自身生成的轨迹上计算教师分布。令第 i 条学生轨迹在词元 t 之前的状态为 $s_{i,t} = (x, y_{i,<t})$ 。其一般形式为逐词元的学生-教师分布散度：

$$\ell_{\text{OPD}}(i, t) = D(\pi_{\theta}(\cdot | s_{i,t}) \| \pi_T(\cdot | s_{i,t})) \quad (3)$$

散度 D 的两种常用实例为反向 KL 与硬目标交叉熵；硬目标取教师分布的最大概率词元 $z_{i,t}^T = \arg \max_v \pi_T(v | s_{i,t})$ ，并以 $-\log \pi_{\theta}(z_{i,t}^T | s_{i,t})$ 为目标（本文主实验采用硬目标，见 § 4.3）。该训练方式使教师监督覆盖学生策略实际访问的状态，但同时引入一个前提：教师模型在这些状态上提供的局部条件分布应当具有教学价值 [4]——§ 3 将直接检验该前提。

2.5 条件教师优势

为刻画教师模型的相对有效性，本文在学生能力区间 b 上定义条件教师优势：

$$M_T(b) = \text{Acc}_T(b) - \text{Acc}_S(b) \quad (4)$$

当 $M_T(b) > 0$ 时，教师模型在该能力区间的平均结果准确率高于学生模型。需要说明的是， $M_T(b)$ 度量结果正确率之差，并不等价于词元级蒸馏质量；即使 $M_T(b) > 0$ ，教师在学生错误前缀上的条件分布仍可能无法有效纠正当前状态。因此，本文将题目级能力优势作为必要但不充分的诊断量，并在 § 3.2 与附录 F 中分别检验题目级能力和状态级可恢复性。

无条件 RL+OPD 负迁移的机制诊断

为把负迁移确立为机制讨论的对象，本节先报告受控四臂实验的现象（数值见表 4，协议与统计口径见 § 5.1）：在共享数据、训练预算与评估协议下，结果监督 RL 相对未经训练的 Base

有稳定增益；在其上无条件叠加教师词元监督（RL+OPD）则显著下降；纯 OPD（无 RL）的点估计亦未超过 GRPO（数值与配对统计见表 4）。随后本节检验该负迁移的机制来源。核心假设是：基础学生在当前数学分布上频繁进入错误推理状态，而 OPD 的词元级监督恰好作用于这些学生访问状态；即使教师从题目根状态具有更高结果正确率，其在已经偏离正确路径的学生前缀上也可能失去部分可恢复性。为区分“教师本身不够强”“上下文变长”与“错误状态语义”三种解释，本文依次报告基础学生能力普查、题目根状态的教师能力对照、错误前缀深度实验、等长匹配状态控制，以及自题目根状态的轨迹级监督与在线状态级监督的受控学习对照。

机制假设

学生侧的错误探索使在线蒸馏暴露于偏离正确推理路径的状态；若教师在这些状态上的条件可恢复性下降，则无条件词元级监督可能成为负迁移来源。该假设需要由状态层面的反事实证据与学习层面的受控实验共同支持，而不能仅凭教师或学生的总体准确率推出。

3.1 基础学生的能力分布与结果信号

对清洗后的 16,164 道训练题，本文使用未经后训练的 Qwen3-1.7B Base（记为 S_0 ）在统一非思考解码协议下进行每题 $n = 8$ 次采样，温度设为 0.6，并以 $\hat{p}(x) = k/8$ 估计逐题成功率。全部失败（0/8）的题目占比最高，成功率分布在整个 0/8–8/8 区间均有覆盖，完整离散分布见表 A1 与图 1(a)。结合式 (2) 的有效组率（图 1(b)）可知，对失败集中的题目，单纯增加优化步数并不总能形成有效的正负组对比；成功率中等偏上的题目才具备稳定的组内信号。该结果说明：结果级信号在相当一部分题目上稀疏，而成功率中等偏上的题目仍占可观比例；错误轨迹仍是训练中需要面对的常见状态。





图 1 · 能力分布与有效组率。(a) 标准化非思考协议下，Qwen3-1.7B Base 在 16,164 道训练题上的 $n = 8$ 离散成功次数分布。(b) 二值结果奖励下，不同采样组大小 G 对应的理论有效组率。能力质量集中于 0/8 区域意味着，仅增加训练步数并不能保证每个采样组都形成正负对比。


该普查只用于刻画学生侧能力结构和组相对学习信号的可获得性；主四臂实验的固定训练池具有独立的历史筛选来源，二者的数据关系见附录 A。

3.2 教师在题目根状态上具有稳定能力优势


若负迁移主要来自教师绝对能力不足，那么教师在题目根状态上也应出现明显的的能力缺口。为检验这一解释，本文在由 Base 学生能力划分的五个区间上进行同题重测，并保持学生与教师的解码协议一致。



(a) Teacher advantage at the problem root



(b) Teacher rescue vs. erroneous-prefix depth



(c) Length-matched state control

图2·教师监督从题目级能力到状态级可恢复性的变化。(a) 教师在五个 Base 能力区间均保持题目级优势；(b) 随错误学生前缀加深，教师救援率持续下降；(c) 长度匹配控制显示，错误前缀的损伤明显大于等长随机上下文，而正确前缀具有促进作用。Panel (b) 与 (c) 使用不同样本集合，因此两个 Root 基线不作直接数值比较。

结果显示，教师从题目根状态作答时在全部能力区间上都保持正的结果优势，且该优势并不随学生能力升高而消失——在 Mid 与 High 两个较高能力区间仍保持接近全样本平均的幅度（各区间细分见图 2(a)）。因此，无条件叠加 OPD 的失败不能简单归因于教师“不会做这些题”；真正需要回答的是，这种题目级优势能否延伸到学生已经偏离正确路径的中间状态。

3.3 错误学生状态造成累积的教师可恢复性损失

题目级优势并不足以保证状态级监督可靠。为直接观察教师在被学生带到错误状态之后的表现，本文以学生错误路径全长的比例档位（25%、50%、75%）截取前缀作为教师输入，并与题目根状态对照，要求教师从该处续写并按同一结果验证器判定。教师救援率随错误前缀加深而持续下降，且下降并非只在某一深度突然出现，而是逐步累积（图 2(b)），形成一条随深度加剧的损伤路径。

上述下降仍可用一个更简单的机制解释：更长的前缀本身加重推理负担。为把“上下文长度”与“状态语义”分开，本文选取同时具备正确与错误前缀、且两类前缀等长的题目，构造三组对照：错误前缀、与其等长的随机文本填充、以及正确前缀。随机填充与错误前缀只在是否携带错误推理语义上不同，可单独度量长度效应；正确前缀则用于检验语义方向。

在等长匹配下，错误前缀使教师准确率明显低于随机文本，正确前缀则明显高于错误前缀，而随机文本与题目根状态之间无可辨识差异（图 2(c)）。若损伤仅由前缀变长造成，错误前缀应与随机文本相当；实际差异说明，决定教师可恢复性的是前缀携带的推理语义——错误语义削弱后续救援，正确语义提供有利的中间状态。

状态级证据

两组实验扮演互补角色：深度 sweep 给出“错误越深、救援率越低”的累积损伤证据；等长匹配控制进一步说明该损伤来自错误推理语义而非上下文长度。二者共同把损伤归因于错误推理语义，而非上下文长度。

3.4 学习层面的方向性验证：轨迹级监督与在线状态级监督

上述状态证据进一步导出一个学习层面的预测：如果无条件的在线状态级监督（在线策略蒸馏，OPD）的部分损伤来自错误状态上的监督错位，那么自题目根状态、以完整可验证正确轨迹为监督对象的轨迹级监督（rejection-sampling fine-tuning, RFT）应能减少这种暴露。为检验该预测，本文构造 RFT 与 OPD 的受控对照：二者共享 Qwen3-1.7B Base 初始化、同一 120 题训练池、batch size 8、120 个优化步、学习率 1e-6、最大序列长度 4,096 与 seed 42，唯一差异在监督所依赖的轨迹来源与粒度——RFT 学习从题目根状态开始的完整正确轨迹，OPD 在学生访前缀上施加教师词元分布。评估使用固定 1,024 题与相同解码协议。

结果以语义正确率报告：该口径把最终答案与参考答案数学等价、但未严格满足既定输出格式的作答同样计为正确，因此它衡量的是学生能否给出正确结论，而不要求其严格贴合某种格式契约。统计采用逐题配对 bootstrap 95% 区间与 McNemar 精确检验。

表 2 · 轨迹级监督（RFT）与在线状态级监督（OPD）的受控学习对照（语义正确率口径，固定 1,024 题）。检验针对逐题配对差异。

Method	Semantic verifier	Δ vs OPD	95% CI	McNemar p
OPD (state-level, online)	265 / 1,024 (25.88%)	—	—	—
RFT (root, trajectory-level)	292 / 1,024 (28.52%)	+2.64 pp	[-0.10, +5.37]	0.0664

以语义正确率衡量，轨迹级监督（RFT）较在线状态级监督（OPD）高 2.64 个百分点，方向与状态错位预测一致；但配对区间仍覆盖零差异（McNemar p=0.066），当前单 seed、120 步证据不足以宣称 RFT 显著更优，只能支持“自根状态学习完整轨迹可能减少错误状态暴露”这一方向性结论。

本节结论

现有证据将负迁移定位为一个具有状态依赖性的监督问题：教师在题目根状态具备能力优势，但该优势不会自动延伸到学生已经偏离正确路径的状态；错误状态越深，教师可恢复性越弱，等长控制表明主要损伤来自错误推理语义而非上下文长度。轨迹级监督的受控结果提供了同方向、尚未显著的补充证据。因此，本文把状态错位视为 OPD 负迁移的直接机制之一，而非唯一原因。这一题目级与状态级的区分对应引言主张 2；§ 3.4 的学习层对照为同方向但尚未显著的支持，见 表 2。

4

AGOPD：优势门控在线策略蒸馏

AGOPD 不改变基础蒸馏散度，而是将教师监督由全局施加改为条件施加：其施加与否由学生侧组相对优势与教师侧可验证正确性共同决定，整体流程如图 3 所示。具体定义见 §4.1–§4.3。

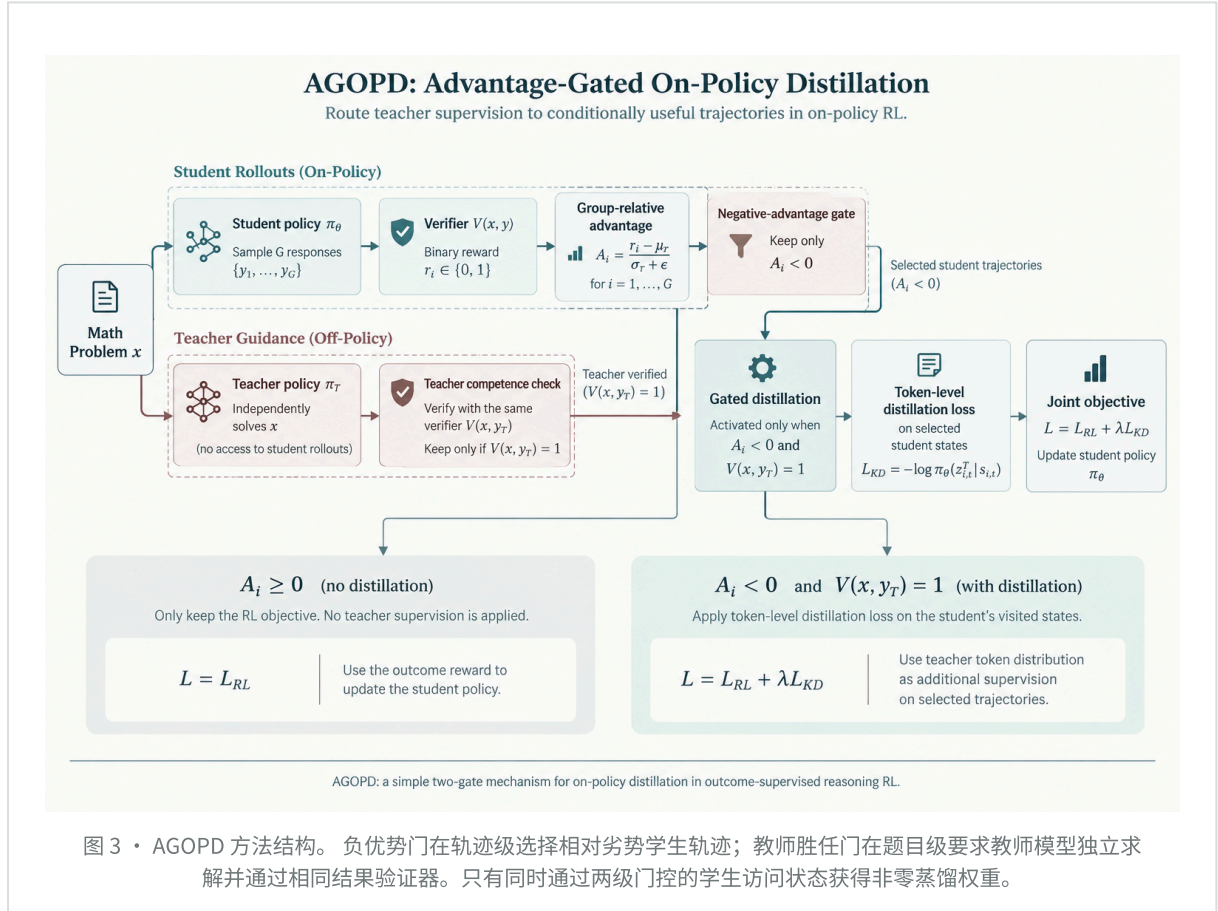


图 3 · AGOPD 方法结构。负优势门在轨迹级选择相对劣势学生轨迹；教师胜任门在题目级要求教师模型独立求解并通过相同结果验证器。只有同时通过两级门控的学生访问状态获得非零蒸馏权重。

4.1 负优势轨迹门控

对于第 i 条学生采样轨迹，定义负优势门：

$$g_A(i) = \mathbb{I}[A_i < \tau_A] \quad (5)$$

主实验采用 $\tau_A = 0$ 。因此，仅当轨迹的组相对优势为负时，该轨迹才进入候选蒸馏集合。实现中进一步使用负优势幅度构造轨迹权重：

$$w_A(i) = \min(\max(-A_i, 0), w_{\max}) \quad (6)$$

其中 $w_{\max} = 2.0$ 。同一问题内，取得非负组相对优势的轨迹仅由强化学习目标优化；负优势轨迹的蒸馏权重随其相对劣势程度增加，并由 $w_{\max}$ 截断。

需要明确门控的作用边界：当一组采样全部失败时，二值奖励组内完全相同，标准化优势 $A_i = 0$ ，式 (5) 的负优势门不激活，蒸馏不会发生。这类“组内无信号”问题属于采样与数据层面 (§3.1 的信号密度)，而非 AGOPD 的适用范围；AGOPD 处理的是混合结果组中相对劣势的轨迹。

4.2 教师可验证胜任门控

负优势只能表明学生轨迹相对于同组样本表现较差，并不能保证固定教师模型在该问题上具有更高可靠性。因此，对于包含候选轨迹的问题，教师模型 π_T 首先独立生成完整解答：

$$y_T \sim \pi_T(\cdot | x) \quad (7)$$

随后使用与学生模型结果奖励一致的验证器判断教师解答是否正确：

$$g_T(x) = \mathbb{I}[V(x, y_T) = 1] \quad (8)$$

最终蒸馏激活变量定义为：

$$g_i = g_A(i) g_T(x) \quad (9)$$

若教师模型的独立解答未通过结果验证器，则该问题下所有候选轨迹的蒸馏损失均被置零。该门控保证的是教师模型在题目级能够独立得到可验证正确答案，而非教师在任意学生前缀上的词元分布均为局部最优监督。

4.3 蒸馏目标与联合优化

设第 i 条学生轨迹在词元位置 t 之前的状态为 $s_{i,t} = (x, y_{i,<t})$ 。对于通过两级门控的学生访问状态，主实验以教师模型概率最大的词元作为硬目标：

$$\begin{aligned}
z_{i,t}^T &= \arg \max_v \pi_T(v \mid s_{i,t}) \\
\ell_{\text{KD}}(i, t) &= -\log \pi_\theta(z_{i,t}^T \mid s_{i,t})
\end{aligned} \tag{10}$$

教师目标在学生模型实际访问的前缀上计算，因此保留在线策略蒸馏的状态覆盖性质；是否施加该词元级监督，则由式 (5) 与式 (8) 的两级门控共同决定。

$$\mathcal{L}_{\text{KD}} = \frac{\sum_i g_i w_A(i) \sum_t m_{i,t} \ell_{\text{KD}}(i, t)}{\sum_i g_i w_A(i) \sum_t m_{i,t} + \epsilon} \tag{11}$$

其中 $m_{i,t}$ 为响应词元掩码。最终目标函数将门控蒸馏项与原 GRPO 目标相加：

$$\boxed{\mathcal{L}_{\text{AGOPD}} = \mathcal{L}_{\text{GRPO}} + \lambda_D \mathcal{L}_{\text{KD}}} \tag{12}$$

主实验中 $\lambda_D = 1.0$ 。因此，AGOPD 与标准硬目标交叉熵蒸馏的差异不在于损失形式，而在于将蒸馏目标的非零作用域限制为满足以下条件的轨迹集合：

$$\mathcal{S}_{\text{AGOPD}} = \{(x, y_i) : A_i < 0 \wedge V(x, y_T) = 1\} \tag{13}$$

式 (10) 的硬目标按被选中轨迹的整条上下文逐位置施加：在学生已正确的词元位置上，教师 $\arg\max$ 与学生已生成词元一致，该损失项退化为自蒸馏式锚定——它不注入新信号，却把策略锚定在自身附近，使策略熵保持在可观测范围而不失控。这一性质是 AGOPD 区别于“只在分歧位置蒸馏”或改用软目标等变体的方法点，其训练动态证据见附录 I。

Algorithm 1 • Advantage-Gated On-Policy Distillation

Input: student policy π_θ , teacher π_T , verifier V , prompt batch $\mathcal{B}$, group size G , threshold $\tau_A = 0$.

1. 对每个问题 $x \in \mathcal{B}$ ，由学生模型在线采样 G 条响应。
 2. 由验证器计算二值结果奖励，并按式 (1) 得到组内相对优势 A_i 。
 3. 对所有学生轨迹计算标准 GRPO 策略目标。
 4. 按式 (5) 选出 $A_i < \tau_A$ 的轨迹，并按式 (6) 的 $w_A(i)$ 加权。
 5. 若某问题至少含一条候选轨迹，则由教师模型独立求解该问题。
 6. 以式 (8) 的验证器检查教师解答；未通过则关闭该问题对应的蒸馏。
 7. 验证通过时，在候选轨迹的前缀状态上计算式 (10) 的词元级蒸馏损失。
 8. 按式 (12) 联合更新学生模型参数。
-

4.4 方法作用范围

AGOPD 的适用范围需要明确区分两类问题。第一，它减少在学生模型已经取得非负组相对优势的轨迹上继续施加教师监督的机会；第二，它过滤教师模型无法独立正确求解的问题。AGOPD 不修改 GRPO 的奖励估计器，也不会为全失败组额外构造正样本。当二值奖励在组内完全相同时，标准化组相对优势为 0，式 (5) 的负优势门不会激活。因此，能力前沿筛选、采样组大小与稳定强化学习配置解决的是“组内是否存在可比较信号”；AGOPD 解决的是在已经产生相对优势之后，教师监督应作用于哪些学生轨迹。

5

实验

本节围绕引言提出的四项研究主张组织实验证据，并在各小节与章末逐一回扣。

5.1 实验设置

模型。 主实验的可训练学生从未经后训练的 Qwen3-1.7B Base S_0 初始化；纯 GRPO、纯 OPD、RL+OPD 与 AGOPD 只在教师监督及其路由方式上不同。固定教师为 Qwen3-4B-GRPO 的 50 步检查点 T 。主实验和主评估均采用非思考模式。本文不将该教师模型解释为普遍优于更大规模基础模型的教师；不同验证子集上的教师排序并不一致，因此其角色仅限于本研究所使用的任务内固定教师。

数据。 训练池来自 DAPO-Math-17K，清洗后包含 16,164 道题。主四臂实验共享同一 1,472 题可学子集（构建口径见 § 2.1 与附录 A）。

训练配置。 主对照采用全参数 FSDP 更新，学习率为 10^{-6} ，KL 损失系数为 0.05，训练批大小为 8，每题采样组大小为 $G = 6$ ，响应长度上限为 2,048。采样参数为 temperature 0.6、top-p 0.95 和 top-k 20。主结果与门控统计均采用同一条 180 个优化步训练轨迹；文中所称 GRPO 基线检查点均指第 180 步检查点。为统一起见，本文把该纯 GRPO 主线记为 180-step GRPO，正文、表格与图注均只使用这一口径。

评估与统计。 主验证集包含固定的 1,024 道题，所有方法共享 seed 42、temperature 0.6、top-p 0.95、top-k 20 与 2,048 词元输出上限。由于比较基于同一批题目，本文采用逐题配对 bootstrap（100,000 次重采样）并辅以 McNemar 精确检验。当前实验仅包含单个训练随机种子，因此这些区间刻画的是固定训练运行上的逐题不确定性，而非训练随机性。

表 3 · 主实验协议。完整运行参数见补充材料中的配置文件与启动脚本。

Item	Main setting	Notes
Student	Qwen3-1.7B Base	full-parameter update from S_0
Teacher	Qwen3-4B-GRPO-50step	fixed teacher
Train subset	1,472 prompts	all methods share the same historical frontier-oriented subset
Batch / group	8 / 6	48 student trajectories per optimization step
Optimizer	AdamW, lr=1e-6	KL loss coefficient 0.05
Decode	T=0.6, top-p=.95, top-k=20	max response 2,048
Main checkpoint	step 180	logs continue to 180 steps
Main evaluation	1,024 fixed prompts	paired statistics

5.2 主要结果：门控缓解无条件蒸馏引起的负迁移

为保持符号与方法名称一致，表 4 中的“GRPO”行记为 S_{RL} ：它是从共同的 S_0 初始化、在相同训练池和优化协议下仅使用结果奖励强化学习得到的训练后参照。其余四臂均从同一 S_0 出发，差异只来自是否加入教师监督及其路由方式。

表 4 · 固定 1,024 题主结果。逐题配对置信区间与 McNemar 精确检验均以 GRPO 为主要参照；AGOPD 与 GRPO 的差异未达到统计显著性，该结果不等同于统计等价性。

Method	Correct / 1024	Accuracy	Δ vs GRPO	Paired 95% CI	McNemar p
Base	239	23.34%	-5.08pp	[-7.71, -2.44]	0.00025
GRPO	291	28.42%	—	—	—
OPD	263	25.68%	-2.73pp	[-5.47, 0.00]	0.0622
RL + OPD	247	24.12%	-4.30pp	[-6.93, -1.66]	0.00184
AGOPD	277	27.05%	-1.37pp	[-4.10, +1.37]	0.360

表 4 的主对照给出两组核心结论。其一，结果监督 RL 相对未经训练的 Base 有稳定增益，但在其之上无条件叠加教师词元监督（RL+OPD）会显著拉低准确率（配对区间不含 0）。其二，双重门控（AGOPD）收回了该损失的大部分，却未超越纯结果监督：相对 GRPO 的剩余差异的置信区间仍跨越 0，故不能判定蒸馏目标优于纯 RL。固定评估与逐题配对统计见表 4。




图4 · 难度分层能力轮廓（雷达）。五条半径对应按 Base 学生 $n = 8$ 能力估计划分的五个区间（Hard→Easy），每条折线给出一种模型在该区间内的严格验证准确率；教师为固定 Qwen3-4B-GRPO-50 检查点，与学生五方法同一固定 1,024 题口径。教师轮廓在多数区间位于最外层，仅 High 区间略低于 GRPO。

图4的难度分层轮廓显示，AGOPD的恢复呈非均匀：它在Hard、Mid的点估计高于对应GRPO、在Easy与GRPO接近，在Low明显偏低，在High只部分收回RL+OPD的损失；固定教师轮廓在多数区间位于最外层。未做区间级显著性分析，该轮廓仅作为描述性能力结构，本文不据此宣称任何区间上的稳定优势；多次采样稳健性见附录G。

主要结果

AGOPD的实证作用是缓解无条件RL+OPD所引入的负迁移，而非证明蒸馏目标普遍优于纯GRPO。

5.3 门控动态与蒸馏作用域

§5.2的恢复差需要机制解释。训练全程统计（图5）显示，负优势门平均放行约40%的轨迹进入候选，教师胜任门再保留约62%，使AGOPD的平均蒸馏损失降到无条件RL+OPD的约

五分之一（0.177→0.032），而两者的策略熵几乎相同（0.1577 对 0.1571）。




图 5 · 门控动态与蒸馏作用域。(a) 报告 180 个训练步骤聚合后的负优势候选比例，以及条件于候选集合的教师胜任保留比例。(b) 训练日志记录的蒸馏损失七步滑动平均；蒸馏损失同时受掩码、轨迹权重与样本难度影响，仅作为训练诊断量，不作为梯度作用域的独立估计。

这些诊断与“作用域收窄”的解释一致：监督更少而固定验证结果更高（表 4，+2.93pp），故被去掉的监督（施加于优势为正或教师不可解的轨迹）更可能是净有害的；熵几乎相同则排除增益来自全局熵抑制的替代解释。需说明的是，上述关系属于过程诊断；机制层的因果证明仍要求两级门控的独立组件消融（见 § 7.5）。AGOPD 相较 RL+OPD 更优的结论以表 4 的配对检验为准。

5.4 困难桶上的门控蒸馏：低学生成功率区域的边界检验

§ 5.2 与 § 5.3 的结果表明，教师门控的收益需要在低学生成功率区域单独检验。为测量该边界，本文构造困难桶训练集：取能力普查中 $\hat{p} = 0.125$ 的全部 1,120 道题，并随机抽取 2,000 道 $\hat{p} = 0$ 的题（seed 42），共 3,120 道。选择该构成是因为低成功率区域同时具有较弱的学生结果信号和较低的教师绝对正确率；它用于边界诊断，不被解释为教师相对优势变号的直接测试。

以 § 4 的 AGOPD 的软目标变体（该变体以温度锐化的教师软分布替代 § 4.3 的硬目标，仅用于本边界检验）在该桶上从第一轮 RL 检查点继续训练 180 步，固定 1,024 题、2,048 词元预算的严格验证评估准确率为 28.22%（95% 配对区间相对 GRPO 基线包含零点），与起点 28.42% 相比无明显提升亦无显著损伤。结合 § 5.2 的负迁移结论，该结果表明：门控蒸馏的作用是避免无条件叠加造成的损伤，而不是在教师绝对正确率较低的区域创造已被验证的额外

收益；轨迹级迁移的可行性则见附录 D 与附录 F。两种作用域在难度轴上的侧重关系见图 6（示意，非数据）。




图 6 · 门控蒸馏作用域示意（非数据图）。横轴难度向右增加，纵轴表示侧重；红色为高难度、低学生成功率区（困难桶，门控难有额外增益），绿色为较易区（舒适池）。该图仅为概念示意，不对应任何具体数值。

证据—主张对照。

按引言研究主张组织：主张 1 的逐题证据在表 4 的 RL+OPD 行（相对 GRPO -4.30pp，配对区间不含 0）；主张 2 由第 3 章承担（题目级教师优势见图 2(a)，状态级损伤见图 2(b)/(c)）；主张 3 在表 4 的 AGOPD 行（+2.93pp 恢复）与图 4 的非均匀恢复轮廓；主张 4 由 § 5.3 的门控统计与蒸馏损失（作用域条款）与 § 5.4 的困难桶边界承担，其中学生训练阶段维度见附录 D。

相关工作

6.1 结果监督推理强化学习

数学推理强化学习的重要优势在于最终答案可以由规则或自动验证器直接判定。DeepSeekMath 提出 GRPO，以组内相对优势替代独立价值模型，从而降低推理强化学习的训练开销 [1]。DAPO 在此基础上进一步研究动态采样、裁剪策略、词元级策略梯度及超长响应控制等稳定性问题 [2]。DeepSeek-R1 则展示了可验证奖励在大规模长链推理训练中的可扩展

性 [3]。与上述工作不同，本文不修改 GRPO 的优势估计机制，而是研究当词元级教师监督与结果监督强化学习联合时，教师信号应当作用于哪些学生轨迹。

6.2 在线策略蒸馏与强化学习—蒸馏联合训练

Agarwal 等提出的 Generalized Knowledge Distillation (GKD) 在学生模型自生成输出上计算教师反馈，以减轻自回归模型训练分布与推理分布之间的偏移，并讨论了其与强化学习微调的联合使用 [4]。随后，G-OPD 将在线策略蒸馏解释为带有 KL 约束的密集强化学习特例，并通过奖励尺度和参考模型设计扩展标准 OPD [5]。这类方法主要调整蒸馏目标的形式或相对权重；AGOPD 保留基础 GRPO 与蒸馏目标，重点改变蒸馏项的非零作用范围。

6.3 能力感知与能力前沿蒸馏

PACED 明确建模学生模型的题目级成功率，并指出蒸馏梯度质量在过难和过易区域都会下降，因此使用基于成功率的能力前沿加权，使训练更加集中于学生的近端发展区域 [7]。SEAD 则从词元、训练阶段和题目三个尺度利用教师—学生熵差与课程机制实施能力感知监督 [8]。这些工作说明，“蒸馏需要依据学生能力进行条件化”并非本文独有观点。AGOPD 的区别在于，它直接复用联合强化学习批次中已计算的逐轨迹组相对优势作为学生侧选择信号，并使用相同结果验证器进行题目级教师胜任度检查。因此，AGOPD 的门控变量来自当前强化学习轨迹的相对结果信号，而非离线成功率估计或熵统计。

6.4 教师不确定性、词元分布与在线蒸馏动力学

EOPD 针对高教师熵词元动态调整正向与反向 KL，以改善生成多样性 [6]；Tail-Aware OPD 指出仅对 top-k 概率重新归一化会丢失尾部分布信息，并显式恢复尾部概率质量 [10]。Rethinking OPD 从教师—学生推理模式兼容性、教师是否具备学生缺失能力以及学生访问状态的覆盖程度等角度分析在线蒸馏的有效条件 [9]，其后续工作进一步讨论极少训练样本条件下的状态覆盖与对齐速度 [11]。这些工作关注词元级或状态级教师分布质量；本文的条件教师优势和结果验证门控位于题目级与轨迹级，两类信号具有互补性。题目级教师正确性并不能保证教师在每个错误学生前缀上都提供最优词元分布，这也是 AGOPD 的重要局限。

讨论与局限

7.1 组内对比不足与教师路由属于两个不同瓶颈

全失败组不激活负优势门，属于“组内是否存在可学习对比”的数据与采样瓶颈（见 § 3.1）；教师词元级监督应作用于哪些已产生相对优势的轨迹，则是方法作用域问题。二者已在 § 4.4 明确区分，本局限不再展开。

7.2 可验证教师正确性只是教师局部质量的代理变量

教师胜任门要求教师模型从头独立求解问题并通过结果验证器。该条件能够过滤教师模型无法正确完成整个问题的情况，但不能证明教师在任意学生前缀 $s_{i,t}$ 上均提供低噪声、局部一致的条件分布。学生轨迹可能已经进入不可恢复的错误分支，而教师从头求解正确并不意味着其在该错误前缀条件下的词元分布仍然是最优教学信号。更细粒度的路由可以进一步结合教师熵、学生—教师状态兼容性、前缀可恢复性或局部验证信号。

7.3 教师有效性相对于持续变化的学生模型定义

Stage-2 多阶段实验表明，第一阶段中有效的固定教师并不保证在后续学生检查点上继续产生相同收益。该现象与条件教师优势的基本观点一致：教师质量不是绝对属性，而是相对于当前学生策略、训练分布和解码协议定义的。本文的 Stage-2 结果不足以将性能变化唯一归因于教师过时，但明确说明教师选择和胜任度判断需要随训练阶段重新评估。

7.4 数据来源与解码模式限制了外推范围

主四臂实验使用的 1,472 题历史训练子集形成于标准化能力普查之前，其早期筛选工件未在所有阶段统一显式关闭思考模式。因此，16,164 题非思考能力普查应被视为信号结构诊断，而非主训练子集的严格生成规则。此外，非思考与思考模式下的绝对能力存在明显差异，因此本文的全失败比例结论仅适用于标准化非思考协议。

7.5 统计范围与缺失消融

当前主结果来自单个训练随机种子。逐题配对 bootstrap 和 McNemar 检验能够量化固定训练检查点在验证题上的不确定性，但不能替代独立训练重复。正式大规模验证应优先增加 GRPO、RL+OPD 和 AGOPD 的独立训练种子，并补充仅使用负优势门或仅使用教师胜任门的组件消融，以区分两级门控各自的贡献。

7.6 计算开销

AGOPD 需要在负优势候选问题上调用固定教师模型，并在学生访问状态上计算蒸馏目标，因此其计算开销高于纯 GRPO。教师胜任门减少了无效教师监督，但仍引入额外推理和词元级前向计算。后续工作需要评估门控阈值、教师调用比例和能力恢复之间的计算—性能权衡。

结论

本文研究了结果监督强化学习中教师监督的条件适用范围。在未经后训练的 Qwen3-1.7B Base 初始化的受控实验中，无条件 RL+OPD 相对稳定的 GRPO 出现显著的逐题性能下降（表 4）；固定教师在题目级结果上保持非负优势，但该优势在学生错误状态上明显折损。基于这一区分，AGOPD 以组相对优势与可验证教师正确性两级门控限制蒸馏作用域，在无门控 RL+OPD 基础上带来可测量的恢复，而相对纯 GRPO 的剩余差异在当前配对评估中未达显著。

证据可归纳为一条因果链：无条件在线蒸馏的负迁移显著且可测；门控能消除该损伤，却暴露固定教师词元级蒸馏在此设定下的能力上限——AGOPD 不超越纯结果监督；附录 D 的多阶段与轨迹级探索进一步提示，在长输出预算下序列级注入完整轨迹可能带来正向转移，但该部分属探索性点估计（非配对、跨预算不可比），不作主结论。

APPENDIX A

能力普查与数据来源

A.1 普查协议与离散能力分布

本文使用标准化非思考协议对清洗后的 16,164 道训练题逐题采样 $n = 8$ ，以八次采样中通过结果验证器的次数定义 $\hat{p}(x) = k/8$ 。表 A1 给出完整离散分布。该普查用于诊断结果监督的信号密度，不被用作主四臂方法比较的额外训练数据。

表 A1 · 标准化 16,164 题能力普查的完整离散分布。正式统计口径以本表九档离散结果为准。统一能力普查中，满足 $\hat{p} \geq 0.25$ 的题目共 6,162 道，因此 1,472 题主训练子集不被解释为该阈值的直接切片。

Success count / 8	Prompts	Fraction
0/8	7,905	48.90%
1/8	2,097	12.97%
2/8	1,383	8.56%
3/8	985	6.09%
4/8	928	5.74%
5/8	809	5.00%
6/8	694	4.29%
7/8	684	4.23%
8/8	679	4.20%

A.2 训练池来源与实验边界

主四臂实验的训练子集包含 1,472 道题，来自标准化普查之前的前沿筛选流程。它是四种方法共享的固定训练池，而不是由当前普查阈值直接切片得到的集合。困难桶实验另取全部 1,120 道 $\hat{p} = 0.125$ 题目，并从 $\hat{p} = 0$ 区域随机抽取 2,000 道题（seed 42），共 3,120 道。将三类数据对象分开记录，可以避免把诊断普查、主训练池和边界实验混为同一数据生成过程。

因此，正文关于全失败题目的结论仅指表 A1 中 0/8 档的普查分布；主四臂实验的因果比较来自共享 1,472 题训练池；困难桶结果则只回答低学生成功率区域的边界问题。三者的协议关系、样本用途和可比较范围不应相互替代。

APPENDIX B

优化配置选择与稳定性诊断

本附录说明主四臂实验的优化配置如何确定。诊断实验改变更新通道、学习率和 KL 约束，而保持任务、模型规模和基本采样协议不变；这些结果用于排除明显不稳定的训练路径，不作为 AGOPD 的性能证据。表 B1 将每个配置的观察、用途和最终处置写明，以避免把探索性失败运行误读为方法结果。

B.1 调试链：从更新通道到学习率与 KL 约束

确定主协议的过程按“能训得动 → 训得稳”两条线展开。第一条线是更新通道：LoRA (r16) 在 $lr=10^{-4}$ 与 3×10^{-4} 下的梯度范数仅约 0.03，较全参数的 0.5–1.4 低一个量级（图 B1(a)），策略梯度损失也几乎不动（图 B1(b)）。这类配置无论怎样提高 LoRA 学习率都无法产生可观测的学习信号，因此在表 B1 中被排除，主基线转向全参数更新。

第二条线是学习率与正则。全参数下， $lr=3 \times 10^{-4}$ 在约 30 步内即崩溃：在线得分跌至零、策略熵先升后塌缩（图 B2(b)）； $lr=10^{-5}$ 前段可训，但后期进入“漂移—冗长—截断”循环，响应长度反复撞击 2048 上限（图 B2(a)），得分随之回落。两种失败模式分别指向“更新过大”与“缺乏对策略漂移的约束”，说明单纯降低学习率并不足以保证全程稳定。

据此把学习率降至 10^{-6} ，并叠加 KL 0.05 锚定：策略熵保持平稳、梯度全程非零、得分单调上升（图 B1/B2 的绿色实线），即冻结为四臂主协议。整条调试线把“为何不用 LoRA、为何不是高学习率、为何需要 KL 约束”压缩为一次可复现的排除过程，最终只有冻结后的全参数配置进入方法比较；各失败配置的观察与处置在表 B1 中留档。




图 B1 · 更新通道诊断。full-param $lr=1e-6$ 保持稳定更新，LoRA (r16) 在 $lr=1e-4/3e-4$ 下有效更新弱一个量级：(a) 梯度范数、(b) 策略梯度损失。




图 B2 · 学习率退化与 KL 锚定。全参数 $lr=1e-5$ 进入漂移—冗长—截断循环并崩溃， $lr=1e-6+KL\ 0.05$ 保持稳定：(a) 响应长度（含 2048 上限线）、(b) 在线得分。

表 B1 · 优化配置筛选。候选运行用于确定稳定基线；主结果只使用冻结后的全参数配置，不将候选运行之间的点估计作为方法比较。

Configuration	Observed behavior	Use in the paper
LoRA, $r = 16$, $\text{lr}=10^{-4}$	weak effective update; low gradient magnitude	rejected as the main full-parameter baseline
LoRA, $r = 16$, $\text{lr}=3 \times 10^{-4}$	increasing lr did not recover a reliable learning signal	rejected; retained as an optimization diagnostic
Full parameter, $\text{lr}=10^{-6}$, $\text{KL}=0.05$	stable entropy and nonzero policy gradient	frozen main protocol
Full parameter, higher lr	response-length drift and training degradation	rejected; not used for method comparison

APPENDIX C

主实验训练动态与指标定义

本附录用训练日志检验四臂运行的健康性，并定义正文引用这些日志时使用的指标口径。在线得分、策略熵、响应长度与蒸馏损失逐优化步波动；这里只把它们当作运行诊断量——方法间的比较一律以固定 1,024 题验证为准（表 3/表 4）。

C.1 四方法的运行健康检查

四条主运行在训练全程均未出现崩溃或熵失控（图 C1）。在线得分方面，GRPO、RL+OPD 与 AGOPD 均随时间上升或保持高位，纯 OPD（无 RL）保持低位而平稳；策略熵方面四种方法都在健康区间，AGOPD 与 RL+OPD 的熵轨迹接近（与正文 § 5.3 的“门控不改变全局熵”解释一致），蒸馏相关量亦未出现异常增长。响应长度与截断率的逐步记录用于确认没有预算压力造成的假性提升。

这些观察为正文的方法比较提供运行层面的背书：主结果的差异不是由个别运行的崩溃或截断制造出来的。




图 C1 · 四主线方法的训练健康检查。(a) 在线得分、(b) 策略熵；曲线为七步滑动平均，用于检查是否存在崩溃、熵失控或异常阶段，方法比较仍以固定 1,024 题验证为准。

C.2 指标字典

表 C1 给出正文引用这些日志时各指标的精确定义与诊断含义。

表 C1 · 训练动态指标字典。在线指标用于运行诊断；固定 1,024 题验证结果才用于主结论。

Metric	Definition in the logs	Diagnostic interpretation
Online score	mean verified reward of sampled responses	batch-level training signal, not fixed-set accuracy
Policy entropy	token-level policy entropy on the response	detects concentration or entropy runaway
Response length / clip ratio	sampled response length and fraction at the cap	detects budget pressure and truncation
Distillation loss	masked teacher-student token loss	measures optimization pressure, not correctness

APPENDIX D

轨迹级迁移与共同初始化下的分支对照

词元级在线蒸馏与轨迹级监督在监督粒度与状态条件上存在本质区别：前者在学生实际访问的前缀上施加教师词元分布，后者以完整且通过验证的轨迹为对象、在题目根状态下按序列级目标更新学生。正文 § 3.4 的受控对照已为轨迹级监督提供方向性证据；本附录在更长预算与二阶段设定下检验该结果是否成立，并厘清谱系内部各阶段之间的继承关系。为使论证不受结构误导，本附录将“共同初始化的构造”与“由该初始化展开的受控条件”分列：前两节描述前者，后三节报告后者。

D.1 轨迹级监督对象与初始化的构造

轨迹级监督对象以既有的结果监督学生为生成策略。对每一训练题，策略独立采样 $n=8$ 次，结果验证器判定每条解答的正误；某题可提供监督样本的题级接受率定义为验证通过的样本比例：

$$\rho(x) = \frac{1}{n} \sum_{i=1}^n V(x, y_i), \quad y_i \sim \pi_{\theta}(\cdot | x) \quad (\text{D.1})$$

以该策略对全部训练题采样并保留验证通过轨迹，清洗至标准答案之前，得到一组携带完整解题链的序列级监督样本。监督对象只包含最终正确且自题目根状态完整的轨迹，因而学生可学习成功路径的中间步骤，而非在已访问前缀上拟合局部词元。

序列级监督在固定分布上的重复暴露会引起过拟合，故需确定停止时机。训练以固定预算逐检查点评测，正确率随步数呈单峰形态（图 D1）：峰值检查点高于初始结果监督学生在同一预算下的水平，此后回落。回放样本高度集中于学生几乎全错的低成功率区域，训练后期在该窄子分布上反复拟合而缺乏新覆盖，构成子分布过拟合；监督信号本身未变，变化的只是模型在窄子分布上的重复暴露。据此选择峰值检查点作为后续初始化的组成部分。




图 D1 · RFT-SFT 检查点探针（4,096 词元预算，固定 1,024 题）。实线为 RFT-SFT 检查点在同一预算下的准确率，虚线为 180 步 GRPO 学生的参照水平（数值见表 D1）；曲线在约 3,000 步处达到峰值后回落。该图为检查点探针，不作显著性解读。

D.2 共同初始化与评估边界

将结果监督学生的训练检查点与轨迹级监督的峰值检查点按权重平均，构成二阶段训练的共同初始化。需要明确其评估边界：平均后的模型未作重新评估，因此对共同初始化的描述只能引用轨迹级监督峰值检查点的探针值（表 D1 首行），而不能给出该初始化本身的正式数值。此边界决定了后续比较采用分支间相对差异的形式，而非对初始化绝对增益的推断。

D.3 共同初始化下的分支对照

为检验在已具备轨迹级热启动的条件下，是否叠加固定教师在线词元蒸馏能否产生额外收益，本文从共同初始化出发，在共享训练数据与预算下比较三组受控条件：纯结果监督（GRPO）、叠加固定教师门控蒸馏（AGOPD，门控机制同正文 § 4），以及改变预算与长度的长度受控 GRPO。三者的唯一差异被限定在是否使用蒸馏以及预算、长度设置上。

表 D1 · 共同初始化及其后的分支对照。首行为合并初始化，其后三支共享该初始化，差异仅在于是否叠加固定教师门控蒸馏（GRPO 与 AGOPD 分支）以及训练预算与长度设置（长度受控分支）。首行的 @4,096 数值为 RFT 检查点探针而非合并后复评，@2,048 未复评；各数值均为固定 1,024 题评估下的探索性点估计（单 seed、非配对、跨预算不可比）。

Stage / init & branch	Acc @2,048	Acc @4,096	Completion @2,048	Analysis role
Warm-start init (GRPO-180 ⊕ RFT-SFT ck3,000)	—	≈33.5 (ck3,000 probe)	—	common init (merged); post-merge eval not re-measured
Branch • GRPO (240 steps)	29.10%	33.20%	78.8%	2-phase result-RL from common init
Branch • AGOPD (240 steps)	27.05%	29.20%	69.6%	+ fixed-teacher gated distillation
Branch • GRPO, length-controlled	30.57%	31.35%	91.8%	budget/length sensitivity

表 D1 的观测可归纳为三点。其一，叠加固定教师门控蒸馏的分支在长预算下低于纯结果监督分支，也低于共同初始化；其二，纯结果监督分支与共同初始化在长预算下大致持平，未表现出可辨别的绝对增益；其三，长度受控分支提高完成率与短预算点估计。第一点与“固定教师的价值需随学生阶段重新评估”的论断一致，即已具备较强热启动时，固定教师词元蒸馏不再提供有效增益。受 D.2 所述评估边界限制，上述观测只支持分支间相对比较，不支持任何绝对增益表述。

D.4 预算与长度作为独立维度

长度受控分支用于分离预算、长度与监督形态两类效应。它从同一初始化出发，在更长输出预算下训练，完成率显著上升，而长预算点估计未单调高于纯结果监督分支。该结果说明长度是独立于监督形态的调节变量，不单独承担能力增益的解释。

D.5 收敛与未直接验证

综合以上观测：轨迹级注入在长预算下可超过未经注入的结果监督学生；在已具备轨迹级热启动时，继续叠加固定教师在线词元蒸馏不产生增益。两处观察共同支持正文 § 8 关于“监督形态决定收益、固定教师需随阶段重估”的结论方向。受评估边界约束，本附录有三项未直接验证：共同初始化的正式复评、教师在二阶段相对学生能力的变化、以及跨预算的逐题配对统计。因此上述观测属方向性点估计，不构成主文层面的显著性结论。

APPENDIX E

输出预算与思考模式敏感性

本附录将输出预算、思考模式和继续强化学习分开标注。相同检查点在不同输出上限下的结果用于测量截断效应；思考模式对照用于测量显式推理过程的影响；继续强化学习则同时改变模型参数和训练过程，不能与静态解码对照混合解释。表 E1 中的每一行都保留其实际协议差异。

E.1 输出预算与思考模式

表 E1a · 输出预算敏感性。同检查点、同解码模式（非思考），仅输出上限变化；Δ 相对 @2,048 行。

Output cap	Accuracy	Δ (pp)
Stage-2C no-think @2,048	30.57%	—
Stage-2C no-think @4,096	31.35%	+0.78

APPENDIX F

真实错误轨迹上的状态级可恢复性

本附录回答一个比“错误前缀越长是否越难”更严格的问题：学生模型在真实生成中何时首次离开可验证的推理路径，离开后错误状态是否持续，以及教师在同一状态下是否仍能恢复。为回答该问题，先对学生真实轨迹做语义审计，以首次可验证错误单元的起始词元作为状态锚点，从而把“错误进入”“错误持续”与“教师救援”拆成三个可观测事件。

正式采样使用 Qwen3-1.7B Base 在固定验证题池上对 200 道题各采 8 条真实轨迹，其中 86 道题同时出现正确与错误轨迹。本附录的状态级部分只取其中 8 道题的高置信人工复核配对，故所有聚合结果均为方向性证据，不代表 200 题总体估计。

F.1 真实轨迹与首次错误标注

状态级测量在 8 道高置信人工复核配对(每题含一条错误轨迹与一条同题正确轨迹)上进行,汇总见表 F2;此处以其中一例(gcd 互素误读,锚点 92 词元)在 F.3 完整演示同状态续写的读取口径,其余配对不再逐卡展开。

表 F1 · 演示例的首次可验证错误标注(测量覆盖 8 道复核配对,汇总见表 F2)。锚点词元偏移相对学生回答,不含用户 prompt。

Case	Error class	First-error anchor	Failure mechanism
Case 1	Reading error · coprimality	92 tokens	gcd(N,20)=1 misread as “not divisible by 4 or 5” ; factor to exclude is 2, not 4.

F.2 观测:教师能否把错误状态救回

把错误轨迹在首次可验证错误处截断,此前缀不加任何纠错提示,原样交给教师模型,令其独立续写 8 条,由验证器判定最终答案;答对比例即该状态下的教师救回率。为排除“这题本来难答”的解释,把同一道题的正确轨迹在相同相对位置截出对照前缀,测同一指标;两者之差才归因于“身处错误状态”本身。

进一步问:错误越深,教师越难救回吗?把同一错误轨迹在锚点之后再向前 64 词元处截断——此时学生已在错误口径里写得更远——重复上面测量,比较两个位置上的救回率及其相对对照的缺口。

本文称续写起点取自错误轨迹的前缀为“已错前缀”,取自同题正确轨迹同位位置的前缀为“同题正确前缀(对照)”。教师始终在同一前缀上继续,不额外获得“请纠错”类提示。结果见表 F2。

表 F2 · 教师救回率:从已错前缀续写 vs 从同题正确前缀(对照)续写,8 道复核配对 × 8 次续写。Δ = 已错 - 正确(pp);95% CI 以 prompt 为聚类单位做 bootstrap;根状态下两前缀为同一份文本,Δ 恒为 0。

State	Wrong prefix	Correct-prefix control	Δ(pp)	95% CI
Root state	21 / 64 (32.8%)	21 / 64 (32.8%)	+0.0	[+0.0, +0.0]
First-error anchor	26 / 64 (40.6%)	40 / 64 (62.5%)	-21.9	[-46.9, +0.0]
+64 tokens after anchor	12 / 64 (18.8%)	35 / 64 (54.7%)	-35.9	[-73.4, -6.3]

读表:错误刚发生时,教师已出现约 22 pp 的救回缺口;深入错误轨迹 64 词元后,缺口扩大到约 36 pp,且 95% CI 不再含 0——错误状态对教师救援的损伤随偏离加深而累积。逐案例的续写过程与失败位置分析见 F.3。

F.3 逐案例:一例完整演示

下面以互素误读一例(gcd,锚点 92 词元)把 F.2 的读取口径落到文字上:灰框为学生错误轨迹的完整步骤,红块=错误起点,紫块=距错误 +64 词元的状态;每个观测位置给教师续写两栏全文(红=已错前缀,青=同题正确前缀对照),错处红字、改对处青字。其余复核配对按同一口径测量,汇总见表 F2,不再逐卡展开。

APPENDIX F · F.3 示例

Case 1 · gcd(N,15)=gcd(N,20)=1

灰底=学生错误轨迹的完整步骤(去重清洗)。红块①=错误起点;紫块②=+64 状态。每观测点两栏:红=已错前缀续写全文,青=同题正确前缀对照续写全文(样本原样展示,不截短)。

学生错误轨迹 · 完整步骤(清洗)

① 错误起点

② +64 状态

Condition 3: gcd(N, 20) = 1
This means N must be coprime with 20.
- gcd(N, 20) = 1 ⇒ gcd(N, 4) = 1 and gcd(N, 5) = 1
So, N must not be divisible by 4 or 5.
Combining the conditions:
- gcd(N, 5) = 1 (from both 15 and 20)
- gcd(N, 4) = 1
- gcd(N, 3) = 1
So, N must be coprime with 4, 3, and 5.
This is equivalent to saying N must be coprime with 60 (since lcm(4, 3, 5) = 60).

位置 A · 错误起点 t* 表 F2 锚点行

教师续写 · 已错前缀

gcd(N, 20) = 1 , which means N must not be divisible by 2 or 5.
4. N is a 5-digit number (i.e., between 10000 and 99999), and the leading digit cannot be zero.
Let’ s break this down step by step.

Step 1: Total number of 5-digit numbers with digits ≤ 3
We are looking for 5-digit numbers where each digit is in the set 0, 1, 2, 3, but the first digit cannot be 0.
- First digit: 3 choices (1, 2, 3)
- Remaining 4 digits: 4 choices each (0, 1, 2, 3)
So the total number of such numbers is:
3 × 4^4 = 3 × 256 = 768

Step 2: Eliminate numbers divisible by 2 or 5
We are told that gcd(N, 20) = 1 , so N must not be divisible by 2 or 5.
So we must exclude numbers divisible by 2 or 5.
We will use the inclusion-exclusion principle to count how many of the 768 numbers are divisible by 2 or 5.

Count of numbers divisible by 2:

A number is divisible by 2 if its last digit is even (0, 2).

- First digit: 3 choices (1, 2, 3)
- Last digit: 2 choices (0, 2)
- Middle 3 digits: 4 choices each

So total numbers divisible by 2:

$$3 \times 4^3 \times 2 = 3 \times 64 \times 2 = 384$$

Count of numbers divisible by 5:

A number is divisible by 5 if its last digit is 0 or 5. But we are only allowing digits ≤ 3 , so only 0 is allowed.

- First digit: 3 choices (1, 2, 3)
- Last digit: 1 choice (0)
- Middle 3 digits: 4 choices each

So total numbers divisible by 5:

$$3 \times 4^3 \times 1 = 3 \times 64 = 192$$

Count of numbers divisible by both 2 and 5 (i.e., 10):

A number divisible by 10 must end in 0 and be even (which it is, since it ends in 0).

- First digit: 3 choices (1, 2, 3)
- Last digit: 1 choice (0)
- Middle 3 digits: 4 choices each

So total numbers divisible by 10:

$$3 \times 4^3 = 3 \times 64 = 192$$

Use inclusion-exclusion to find numbers divisible by 2 or 5:

$$\text{Divisible by 2 or 5} = 384 + 192 - 192 = 384$$

So, the number of numbers not divisible by 2 or 5 is:

$$768 - 384 = 384$$

Step 3: Eliminate numbers divisible by 3

We are told that $\gcd(N, 15) = 1$, so N must not be divisible by 3 or 5. Since we already excluded numbers divisible by 5, we now only need to exclude numbers divisible by 3.

We need to count how many of the 384 numbers are divisible by 3.

A number is divisible by 3 if the sum of its digits is divisible by 3.

We are considering all 5-digit numbers with digits in 0, 1, 2, 3 and first digit not zero.

We can use the fact that the number of such numbers where the sum of digits is divisible by 3 is exactly one-third of the total (since the possible digit sums modulo 3 are evenly distributed).

So, of the 384 numbers not divisible by 2 or 5, one-third are divisible by 3.

$$384 \div 3 = 128$$

So, the number of numbers not divisible by 2, 3, or 5 is:

$$384 - 128 = 256$$

Final Answer:

256

教师续写 · 同题正确前缀(对照)

all digits of N must be in the set 0, 1, 2, 3, and the first digit cannot be 0 (since N is a 5-digit number).

So, the first digit has 3 choices: 1, 2, 3

Each of the remaining 4 digits has 4 choices: 0, 1, 2, 3

So, the total number of 5-digit numbers with digits no greater than 3 is:

$$3 \times 4^4 = 3 \times 256 = 768$$

Step 2: Apply the gcd conditions

We need to find the numbers N such that:

$$\gcd(N, 15) = 1 \text{ and } \gcd(N, 20) = 1$$

We can simplify this by noting that:

$$\gcd(N, 15) = 1 \Rightarrow N \text{ is not divisible by 3 or 5}$$

$$\gcd(N, 20) = 1 \Rightarrow N \text{ is not divisible by 2 or 5}$$

So, combining these, we get that N must not be divisible by 2, 3, or 5.

Thus, we need to count the number of 5-digit numbers with digits in 0, 1, 2, 3, first digit not 0, and not divisible by 2, 3, or 5.

Step 3: Use inclusion-exclusion

We count the total number of such numbers, and subtract those divisible by 2, 3, or 5.

Let's define the set of all such 5-digit numbers with digits ≤ 3 and first digit $\neq 0$: $S = 768$, as calculated above.

Let:

- A : numbers divisible by 2

- B : numbers divisible by 3

- C : numbers divisible by 5

We want to count $|S \setminus (A \cup B \cup C)|$, which is:

$$|S| - |A| - |B| - |C| + |A \cap B| + |A \cap C| + |B \cap C| - |A \cap B \cap C|$$

We now compute each of these.

Step 4: Count numbers divisible by 2

A number is divisible by 2 if its last digit is even.

Digits allowed are 0, 1, 2, 3, so even digits are 0, 2.

So, last digit has 2 choices.

First digit: 3 choices (1, 2, 3)

Middle 3 digits: 4 choices each

So, total numbers divisible by 2:

$$3 \times 4^3 \times 2 = 3 \times 64 \times 2 = 384$$

Step 5: Count numbers divisible by 3

A number is divisible by 3 if the sum of its digits is divisible by 3.

We count how many of the 768 numbers have digit sums divisible by 3.

This is more complex, but we can use the fact that the total number of such numbers is $768/3 = 256$, assuming uniform distribution (which is true because digits are chosen from a uniform set and the total is divisible by 3).

$$\text{So, } |B| = 256$$

Step 6: Count numbers divisible by 5

A number is divisible by 5 if its last digit is 0 or 5.

But digits allowed are only 0, 1, 2, 3, so only 0 is allowed.

So, last digit must be 0.

First digit: 3 choices

Middle 3 digits: 4 choices each

Last digit: 1 choice (0)

So, total numbers divisible by 5:

$$3 \times 4^3 \times 1 = 3 \times 64 = 192$$

Step 7: Count numbers divisible by 2 and 3

These are numbers divisible by 6.

We count how many of the 768 numbers are divisible by 6.

Since $6 = 2 \times 3$, and 2 and 3 are coprime, the numbers divisible by 6 are those divisible by both 2 and 3.

We…(语料至此截断)

差异:已错前缀一侧第一句即把 4 改回 2,按正确口径继续并收尾 256;对照侧同一句一致,救回差距小。

位置 B · t* + 64 词元 表 F2 +64 行

教师续写 · 已错前缀

that:

- All digits are in 0, 1, 2, 3.

- N is **not divisible by 2, 3, 4, or 5**.

- The first digit is not 0.

So, N must be coprime with 60 (since $\gcd(N, 60) = 1$), because $\text{lcm}(15, 20) = 60$.

But we can check divisibility conditions directly.

Step 2: Count all 5-digit numbers with digits ≤ 3

We are to count all 5-digit numbers where each digit is in 0, 1, 2, 3 and the first digit is not 0.

- First digit: 1, 2, or 3 $\rightarrow 3$ choices.

- Remaining 4 digits: 0, 1, 2, or 3 $\rightarrow 4$ choices each.

So, total such numbers $= 3 \times 4^4 = 3 \times 256 = 768$.

Step 3: Exclude numbers divisible by 2, 3, 4, or 5

We need to count how many of these 768 numbers are not divisible by 2, 3, 4, or 5.

We use the inclusion-exclusion principle to count how many numbers are divisible by at least one of these, and subtract that from 768.

Let's define:

- A : numbers divisible by 2

- B : numbers divisible by 3

- C : numbers divisible by 4

- D : numbers divisible by 5

We need to find $|A \cup B \cup C \cup D|$, and subtract it from 768.

We will calculate the number of such numbers divisible by each of the divisors, and their intersections.

Step 4: Count numbers divisible by each divisor

We will count how many of the 768 numbers are divisible by 2, 3, 4, or 5.

Divisible by 2:

A number is divisible by 2 if its last digit is even (0, 2).

- First digit: 1, 2, or 3 $\rightarrow 3$ choices

- Last digit: 0 or 2 $\rightarrow 2$ choices

- Middle digits: 0, 1, 2, 3 $\rightarrow 4$ choices each

So, numbers divisible by 2:

$$3 \times 4^3 \times 2 = 3 \times 64 \times 2 = 384$$

Divisible by 3:

A number is divisible by 3 if the sum of its digits is divisible by 3.

We can count this by checking all 768 numbers and counting how many have digit sums divisible by 3.

But it's easier to compute the number of such numbers using modular arithmetic.
Each digit is 0, 1, 2, or 3. So, the total number of 5-digit numbers with digits ≤ 3 is 768.
We can use the fact that the number of such numbers with digit sum divisible by 3 is approximately 13 of the total, because the digits are evenly distributed modulo 3.
So, numbers divisible by 3: $768/3 = 256$
Divisible by 4:
A number is divisible by 4 if its last two digits form a number divisible by 4.
We can count this by considering all possible last two digits (from 00 to 33) that are divisible by 4, and for each, count the number of combinations for the first 3 digits.
There are 16 possible two-digit combinations (from 00 to 33), and only 4 of them are divisible by 4: 00, 04, 08, 12, 16, 20, 24, 28, 32, 36 $\rightarrow$ but only those ≤ 33 are valid.
Valid two-digit combinations divisible by 4: 00, 04, 08, 12, 16, 20, 24, 28, 32 $\rightarrow$ 9 combinations.
So, numbers divisible by 4:
 $3 \times 4^2 \times 9 = 3 \times 16 \times 9 = 432$
Divisible by 5:
A number is divisible by 5 if its last digit is 0 or 5. Since digits can only be 0... (语料至此截断)

教师续写 · 同题正确前缀(对照)

means N must not be divisible by any of the prime factors of 15, which are 3 and 5.
So, N must not be divisible by 3 or 5.
Condition 3: $\gcd(N, 20) = 1$
This means N must not be divisible by any of the prime factors of 20, which are 2 and 5.
So, N must not be divisible by 2 or 5.
Combining conditions 2 and 3, N must not be divisible by 2, 3, or 5.
So, the number N must be coprime with 30 (since $\text{lcm}(15, 20) = 60$, and the gcd condition implies $\gcd(N, 30) = 1$).
Thus, we are looking for 5-digit numbers N with digits in 0, 1, 2, 3, first digit not zero, and $\gcd(N, 30) = 1$.

Step 2: Count all 5-digit numbers with digits in 0, 1, 2, 3, first digit not zero
We count the number of such numbers:
- The first digit: 3 choices (1, 2, 3)
- The remaining 4 digits: 4 choices each (0, 1, 2, 3)
So, total such numbers $= 3 \times 4^4 = 3 \times 256 = 768$

Step 3: Remove numbers divisible by 2, 3, or 5
We need to count how many of these 768 numbers are not divisible by 2, 3, or 5.
This is a classic inclusion-exclusion problem.
Let's define:
- A : numbers divisible by 2
- B : numbers divisible by 3
- C : numbers divisible by 5
We want to count the numbers not in $A \cup B \cup C$, i.e., numbers not divisible by 2, 3, or 5.
So we compute:
Valid numbers = Total numbers - $|A \cup B \cup C|$
Using inclusion-exclusion:
 $|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$
We now compute each term.

Step 4: Count numbers divisible by 2

A number is divisible by 2 if its last digit is even: 0, 2
 So, among the 4 choices for each digit (0, 1, 2, 3), 2 are even.
 Thus, the number of 5-digit numbers with digits in 0, 1, 2, 3, first digit not zero, and last digit even is:
 - First digit: 3 choices
 - 3 middle digits: 4 choices each
 - Last digit: 2 choices (0, 2)
 So, $|A| = 3 \times 4^3 \times 2 = 3 \times 64 \times 2 = 384$

 ### Step 5: Count numbers divisible by 3
 A number is divisible by 3 if the sum of its digits is divisible by 3.
 Let's count how many of the 768 numbers have digit sums divisible by 3.
 This is more complex, but we can use modular arithmetic.
 Each digit can be 0, 1, 2, or 3. Let's denote the digits as d_1, d_2, d_3, d_4, d_5 , where $d_1 \in \{1, 2, 3\}$, and the rest $d_i \in \{0, 1, 2, 3\}$.
 Let's compute the total number of such 5-digit numbers with digit sum divisible by 3.
 This is a standard problem in combinatorics. The total number of such numbers is:
 $13 \times \text{Total numbers} = 13 \times 768 = 256$
 So, $|B| = 256$

 ### Step 6: Count numbers divisible by 5
 A number is divisible by 5 if its last digit is 0 or 5.
 But our... (语料至此截断)

差异与判读:深入 64 词元后,已错前缀一侧把约束写成“2、3、4、5 全排除”并称 $\gcd(N,60)=1$;对照侧仍按只排除 2、3、5。错误惯性带偏后续,教师救不回。

F.4 证据链与解释边界

证据链按四个事件展开。在 200 道题、每道 8 条、共 1,600 条真实轨迹中,1,285 条未通过结果验证,其中 86 道题同时存在正确与错误轨迹,说明模型访问的状态并非沿单一正确路径展开,而是同时包含可比较的成功与失败分支。进入状态级分析前,仅保留能定位到第一处可验证语义错误的轨迹;格式重复、答案抽取失败与截断被单独排除,以免把输出协议问题误判为推理偏移。随后在同一道题、相同相对位置上把错误轨迹与正确轨迹配成对照;只有当错误状态上的教师救援率低于对照时,差异才可归因于状态条件而非题目难度。最后,锚点后 64 个词元的状态用于检验错误是否持续约束后续生成:试点中教师救援的错误一对照差距随偏离而扩大,支持“错误状态具有累积性”的方向性解释。

对在线蒸馏的含义在于:OPD 在学生已访问的状态上施加局部词元监督,一旦该状态偏离可验证路径,教师的局部分布未必仍是可靠的纠错目标。因此,学生状态访问质量是 OPD 健康性的关键调节变量,但并非唯一因素。

需要强调,教师续写并不是对学生答案做强制改写,而是“接着学生的前缀继续生成”,再按最终答案打分——它没有任何修改学生已写文本的能力。因此,一旦学生轨迹进入错误的解空间,教师拿到的前缀本身已是错误推导的延续,其纠错能力也随之失效;这正是表 F2 中救回率随 +64 词元衰减的机制解释,也与正文 4.3 的“仅在教师可信时施加蒸馏”一脉相承。

本附录支持的最强表述是：学生真实生成中的错误状态与教师的后续可恢复性相关，而且偏离持续后差异扩大。它不支持“教师无法救回所有错误状态”，也不支持仅凭 entropy 证明模型发生全局坍塌。本文将“trajectory-level irrecoverability”与训练过程中的 entropy collapse、reward collapse 分开使用；后者必须由逐 step 的训练动态另行证明。

F.5 数据与复现工件

全部数据与工件均存放于项目工件目录：200 题学生真实轨迹、86 条同题配对审计队列、8 条人工复核记录、教师同状态续写样本，以及汇总 JSON 与图表源脚本。正式扩展需把人工复核规模提高到至少 20–30 个题对（prompt 级配对），并据此重新估计总体救援差异。

APPENDIX G

多次采样稳健性（Pass@k）

本附录为固定 1,024 题单次采样结果的补充稳健性检查，用于确认门控方法未引入额外的多样性损失；属描述性证据，不参与显著性检验。

固定验证采用单次采样，无法区分“模型稳定掌握”与“偶尔答对”。为刻画各方法的多次采样覆盖能力，本文在固定 1,024 题验证集的 128 题子集上以 temperature 1.0 每题采样 8 次（协议与主评估一致），报告至少一次答对的累计比例 $\text{Pass}@k$ （图 G1）。GRPO 在 $k \geq 2$ 时不低于其余方法，AGOPD 与 RL+OPD 的曲线接近，说明门控在多次采样视角下同样未引入额外的多样性损失，与主张 3 一致。该子集按文件顺序截取、难度偏易，方法间差距受天花板效应压缩，本图仅作描述性稳健性证据，不参与显著性检验。




图 G1 · 多次采样覆盖 (Pass@k)。

APPENDIX H

底座规模与信号密度：更易学习的探索空间作为解决方向

第三、四章把无条件在线蒸馏的负迁移定位为状态错位型问题：小底座学生在错误状态频繁、教师在这些状态失去部分可恢复性。本附录沿规模轴给出同方向的解决证据：更强的底座在相同采样协议下更容易访问正确的探索状态，既直接提升结果监督 RL 的实际收益，也可能稀释使 OPD 受损的状态错位暴露。以下依次给出普查信号密度（表 H1）、同预算结果监督 RL 的实际效果（表 H2），最后说明该规模证据与前面机制分析的衔接与待验证边界。

H.1 普查口径与信号密度

普查与 A.1 使用相同的干净 chat 渲染与规则打分：1.7B 与 4B 均采用与附录 A.1 同协议的 clean-chat 全量普查：对同一 16,164 题训练集逐题 $n = 8$ 非思考解码，规则验证器打分。把底座规模作为轴后，三个指标同向移动：八次采样全错的题目占比下降、题目平均成功率上升、固定组大小下能形成正负组对比的信号密度上升（表 H1）。组大小取 4、6、8 时排序一致，说明该结论不依赖单一组大小（表 H1）。

表 H1 · 普查信号密度随底座规模。 $S(G) = \mathbb{E}_{\hat{p}}[1 - (1 - \hat{p})^G - \hat{p}^G]$; 1.7B 与 4B 均为同一 16,164 题 clean-chat 全量普查（与附录 A.1 同协议、同规则打分口径），可直接按底座规模比较。

Base model	Census n	$\hat{p} = 0$ (95% CI)	mean $\hat{p}$	S(4)	S(6)	S(8)
1.7B (full)	16,164	48.9% [48.1, 49.7]	0.232	0.301	0.360	0.394
4B (full)	16,164	39.4% [38.6, 40.1]	0.309	0.344	0.411	0.449

H.2 实际效果：同预算结果监督 RL

信号密度只是数据条件化的量；底座规模是否真正转化为结果，需要看同一训练预算下的结果监督 RL 输出。固定 1,024 题、非思考 @2,048、seed 42 的结果正确率（reward 口径，规则验证器判定）下，50 步 GRPO 在 4B 上明显高于 1.7B（表 H2）。该对照同为 50 步、同固定评估口径，但两运行的历史训练批次与更新通道细节不完全受控，差值作方向性参照。更值得注意的是，4B 的起点本身更高，且相对各自 Base 的同预算 GRPO 增量也更大（表 H2）：更强的底座既提供更高的先验起点，也能更充分利用同预算的结果监督信号。在训练过程层面，更大的底座也在相同的 lr=1e-6 全参结果监督 GRPO 协议下更快进入并维持更高的在线结果分（图 H1），与该固定评估差同向。

表 H2 · 结果监督 RL 实际效果随底座规模（reward 口径：规则验证器的结果正确率；固定 1,024、非思考 @2,048、seed 42）。该口径与正文固定评估的 Base 数值一致；两规模 GRPO 均为 50 步， Δ 相对各自 Base。

Base model	Base (reward acc., fixed 1,024)	GRPO-50 (reward acc.)	Δ (pp; GRPO - Base)
1.7B	23.3%	25.4%	+2.1 pp
4B	30.2%	40.2%	+10.0 pp



图 H1 · 结果监督 GRPO 训练曲线随底座规模。在线平均结果分（规则打分）随优化步的变化，5 步滑动平均：4B（50 步）更快进入并维持更高区间，1.7B 主基线整体偏低且到达更慢。两运行均为 lr=1e-6 全参结果监督 GRPO；x 轴为各自优化步，非同步时刻对齐。

H.3 机制衔接：分析到解决方向

前面的机制分析给出负迁移的直接来源：小底座学生在错误路径上访问频繁，而教师在这些状态的可恢复性随错误加深而下降（§ 3.3）。规模证据从两端回应这一来源。其一，更强的底座把全错题占比压低、平均成功率抬高，固定组大小下的信号密度随之上升（表 H1），说明 RL 分组更常包含正样本、可学习的正负对比更易形成。其二，同一训练预算下结果监督 RL 的实际收益随规模上升（表 H2），说明更强的探索空间转化为最终结果。两点放在一起，本文把规模提升视为状态错位型负迁移的候选解决方向：它减少了对教师救援的依赖，也稀释了使 OPD 受损的深错状态暴露。

该方向的边界需显式说明：其一，4B 学生的 OPD / 门控四臂受控对照尚未运行，本附录不能直接宣称规模消除负迁移，只给出信号密度与实际 RL 效果两条同向证据；其二，两运行的批次与通道细节不完全受控，实际效果差值为方向性参照；其三，教师选择（题目级优势）与规模提升正交，规模证据不替代 § 4 的门控机制。前文各章为机制分析，本附录给出的规模路径是需要受控实验确认的解决方向。

APPENDIX I

在线蒸馏的熵—信号两难：锚的作用与 KL/熵罚的局限（探索性）

围绕“在线词元级蒸馏如何学习教师的正确信号”，在默认配置里，hard-CE 蒸馏先在整条学生上下文上逐位置发生（目标取教师 argmax）；本文随后尝试收紧它的位置，只在教师与学生分歧处或教师置信处施加，以期留下信号、去掉无信息分量。这一收紧会连带移除 AGOPD 主配置中“overlap 自蒸馏锚”的隐式作用，使策略熵失去约束；提高 KL 强度或加入熵罚只能推迟熵失控，不能根治。本附录记录该批变体实验的结局：所有变体均未超过纯结果监督基线，据此把“在线词元级蒸馏能否带来增益”收束为机制性边界，而不是超参数问题。

I.1 锚的作用

在默认主配置里，hard-CE 蒸馏先在整条学生上下文上逐位置发生：目标取教师在该位置的 argmax。学生已正确的 overlap 位置上，该目标与学生已生成词元一致，hard-CE 在此退化为“跟随自己”，等于把自蒸馏式熵锚嵌进蒸馏本身；它不传递新信号，却把策略锚定在自身附近，维持可观测的熵与学习稳定。代价是锚与信号耦合，无法只保留“有信息”的蒸馏——把蒸馏收窄到教师 argmax 与学生采样分歧的位置（分歧纯 OPD、分歧 AGOPD），或进一步要求教师在该位置双置信（teachable），即会连带移除该锚。

I.2 软目标到硬目标：熵通道

在改用硬目标之前，AGOPD 曾以教师 top-16 分布、经温度 0.7 锐化的软目标作蒸馏监督。图 I1 比较两版在相同 comfort 池与两级门控下的策略熵轨迹：hard（teacher argmax）全程低而平稳；软目标版整体更高并随步向上漂移，至 94 步提前终止前仍未回到 hard 版的低熵通道。该观察是把蒸馏目标换成教师 argmax 的直接动因。需与后文的删锚变体（图 I2）区分：软版的熵漂移有限，未进入策略熵失控区；完全失控只出现在删锚更彻底的分歧类变体中。





图 I1 • AGOPD 蒸馏目标：软（softT07）对硬（teacher argmax）的策略熵轨迹。硬目标全程低而平稳，软目标整体更高并向上漂移。两版同池（comfort）、同两级门控，仅蒸馏目标不同；软版在 94 步提前终止。曲线为 9 步滑动平均。

I.3 结果


变体训练的观测（表 I1、图 I2）一致：一旦删去 overlap 锚，策略熵随步上升并最终失控，在线结果分同步回落，分歧纯 OPD 最为严重；teachable 变体与熵罚变体只能推迟失控，且熵罚还拖累最终分；提高 KL 系数同样只延后失控。保留锚的 AGOPD 主配置与纯结果监督基线作为健康对照，熵平稳、结果分稳定。

表 I1 · 在线蒸馏熵—信号两难变体。在线熵为逐步 actor 熵（首值→末值或峰）；固定 1,024 为语义正确率（GRPO/AGOPD 行见 § 5.1）。所有变体均未超过纯结果监督的 GRPO 基线。

Variant	Online entropy path	Fixed 1,024	Note
AGOPD main (overlap anchor + gates)	peak ≤ 0.23	27.05%	reference (§ 4/ § 5)
GRPO main (no distillation)	≤ 0.17	28.42%	result-only baseline
disagreement pure OPD (no RL)	0.10 $\rightarrow$ 0.62	8.01%	no RL; hard-CE only at disagreement
teachable AGOPD, KL 0.05	$\rightarrow 0.38$	19.04%	dual-confidence gate
teachable + entropy penalty $\beta 0.02$	$\rightarrow 0.39$	17.48%	entropy-penalty variant
disagreement AGOPD, KL 0.05	$\rightarrow 0.40$ @ step 94	—	guard-killed at step 94
disagreement AGOPD, KL 0.2	$\rightarrow 0.23$ @ step 22	—	interrupted at step 22



(a) 策略熵随训练步



(b) 在线结果分随训练步

图 I2 · 在线蒸馏变体的训练动力学（熵—信号两难）。(a) 删除 overlap 锚的变体策略熵持续爬升，分歧纯 OPD 最严重；(b) 其在线结果分随之塌底。保留锚的主配置与 GRPO 基线作为健康对照。曲线为 9 步滑动平均。

I.4 收敛含义

这批探索与正文的收敛含义一致。在线蒸馏的“熵约束”与“信号选择性”不能解耦：只有在信号的位置蒸馏会连带移除隐式熵锚。KL 与熵罚这类外部制动不能替代结构性锚定，因此 AGOPD 不采用词元级“更纯净”的变体，而是保留 overlap 锚，把选择性放在结果级门（优势门与教师胜任门）。又因全部变体均未超过纯结果监督基线，在线词元级蒸馏在本文设定下被收束为无增益的机制性结论，蒸馏只发生在结果门限定的作用域内。

本文全部在线训练与状态级探针的证据均由 verl v0.8 (FSDP 训练循环) 与 vLLM 0.10 (采样与教师推理) 组成的 rollout 引擎承担。多卡 rollout 的吞吐并不只由引擎单点参数决定, 还由训练进程与采样进程的拓扑 (进程分布、并行切分、权重同步方式) 整体决定。本附录以工程复现说明的形式, 记录为使 $4 \times A100$ 上的在线词元级蒸馏可行而进行的配置优化: 先给出基线拓扑与观测到的瓶颈, 再给出配置改动与实测差异。该说明属于工程复现附件, 不构成方法层面的科学对照。

J.1 基线: 分进程 standalone 拓扑与瓶颈观测

初始部署将训练 actor、学生采样与教师推理作为三个相互独立的进程分别置于单独 GPU: 学生以 FSDP 单卡承担优化步, 单独的 vLLM server 承担学生 rollout, 另一单独的 vLLM server 承担教师推理, 余下 GPU 空闲。推理引擎采用保守参数: 关闭 CUDA Graph (`enforce_eager=True`)、低显存配额、16K 词元量级的批处理上限、默认的并发 worker 数, 各项精确取值见表 J1。每训练步结束后需将学生权重跨进程广播给采样 server, 构成固定开销。

瓶颈观测可归纳为三点。其一, 单步总耗时的构成中, 除生成外的参考前向、actor 更新与跨进程权重同步均占明显比例, 阶段之间存在大量串行等待, GPU 空闲窗口明显。其二, 跨进程权重同步每步固定耗费十秒量级, 与采样体量无关。其三, 提高 vLLM 显存配额未带来端到端吞吐变化, 说明该配置下生成并非受 KV 缓存容量约束; 把空余显存当作必须填满的目标属于误判。上述观测对应的阶段耗时见图 J1。

J.2 优化: 采样拓扑与引擎参数的联合改动

优化遵循“按端到端步耗时分解瓶颈、按阶段归因改动”的原则, 改动分两层: 拓扑层复用 verl 的 actor/rollout 混合部署 (`rollout.nnodes=0`), 使采样 replica 与 actor 同卡共存, 取消独立的 rollout 进程与其带来的权重广播; 并行层将学生改为 2 路 FSDP, 教师改为 TP1 数据并行多 replica 而非 TP2。教师不采用 TP 切分的理由在于, 长文本 (2,048 词元) 生成的吞吐受并发请求数约束大于受单请求延迟约束, TP1 数据并行以更多 replica 放大批并发, 收益高于以张量并行压低单请求延迟; 4B 档教师在单卡 TP1 下已可完整驻留显存。


引擎层同时启用 vLLM sleep mode 与逐步 KV 缓存释放: 引擎在生成间隙释放权重并按需恢复, 配合仅同步可分离的增量 (LoRA delta 语义), 将跨进程权重同步压缩到亚秒级。并发侧提高 AgentLoop worker 数并试探更高的批处理上限 (表 J1)。CUDA Graph (关闭 eager) 在单引擎层面可用, 但在该多进程组合下未能在限定时间内进入首个训练步, 且 sleep/resume 与 graph 捕获存在交互, 故其启用被约束为“先经端到端冒烟验证再进入主实验”。显存配额改为只在出现 KV 不足告警时提高。改动前后配置对照见表 J1。

表 J1 · 采样—推理拓扑与引擎参数优化前后的最小配置对照。逐项设计理由与边界条件见 J.2 正文。

Aspect	Baseline (standalone)	Optimized (hybrid)
Topology	separate processes on separate GPUs	actor/rollout co-located (rollout.nnodes=0)
Student	FSDP, 1 GPU	FSDP 2-way
Rollout	1 standalone server	TP1 hybrid replicas
Teacher	1 standalone server	TP1 × DP (no TP2)
Weights sync	full-weight broadcast	sleep-mode delta (<1 s)
Workers / max tokens	8 / 16,384	16 / up to 32,768
VRAM / CUDA graph	gmu 0.25 / eager	raise only on KV pressure / graph gated on e2e

J.3 实测差异

以同一 1.7B GRPO+OPD（E3 类）任务、同采样预算记录端到端差异。混合拓扑带来的提速并不来自生成本身，而来自参考/评分、actor 更新与权重同步等阶段；分阶段对比与端到端总耗时见图 J1；精确数值、口径与免责说明随图注给出。



More Efficient Training with Rollout Optimization

Optimized (hybrid) training reduces per-step time across all stages, enabling faster iteration.



-7%
Generation
vLLM rollout



-33%
Reference & reward
scoring



-32%
Actor update
optimizer step




-35%
Weights sync
step profile

A

Per-stage mean time


Optimized training is consistently faster across all stages.

● Baseline (standalone)
● Optimized (hybrid)

**B**

End-to-end step time

Overall step time is reduced by 27%, accelerating training iteration.



Engine-layer
weight sync (separate metric)

13 – 15 s → 0.64 – 0.80 s (≈ 95% reduction)

Note: Engine-layer weight sync is a separate measurement from the step-profile metric (13.4 → 8.7 s) and should not share the same axis.

图 J1 • rollout 拓扑优化前后的对比图。灰/主色两档分别对应优化前 standalone 与优化后 hybrid，阶段与总耗时的降幅以百分比标注。数据来自同一 Qwen3-1.7B GRPO+OPD (E3 类) 任务、2,048 词元预算的相邻任务记录：各阶段求和与端到端步总并不相等（步总还包含数据组装、调度等待等未细分开销），引擎层实际权重同步（sleep-mode）为 0.64–0.80 s，与图中步骤档案口径不同；相邻任务实例的耗时对比不作为独立受控基准。

将收益归因到具体改动：actor 更新因 2 路 FSDP 明显缩短；拓扑收敛使参考/评分与调度等待下降；sleep mode 增量同步把跨进程权重同步压到亚秒级。生成阶段变化有限，说明该工作负载下生成并非主要瓶颈。

J.4 经验与可推广规则

- 吞吐评价应以端到端步耗时及其阶段分解为准，GPU 平均利用率不构成等效指标：利用率并不随各阶段交替等待而整体升高。
- 显存配额只有在出现 KV 容量不足时才提高；空余显存不等于必须填满的资源目标。
- 任何引擎参数改动（CUDA Graph、批处理上限、worker 并发）都必须先经端到端冒烟验证再进入主实验，单引擎层可用性不能外推到多引擎组合。
- 权重同步与进程分布属于低垂的固定开销，优先于对生成引擎单点的调参；本优化最终支撑了主实验与各探针采用 3+1 混合拓扑（三卡 actor/rollout 复用、一卡教师）运行。

References

- [1] Shao, Z. et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. 2024.
- [2] Yu, Q. et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale. 2025.
- [3] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025.
- [4] Agarwal, R. et al. On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes. ICLR 2024.
- [5] Yang, W. et al. Learning beyond Teacher: Generalized On-Policy Distillation with Reward Extrapolation. 2026.
- [6] Jin, W. et al. Entropy-Aware On-Policy Distillation of Language Models. ICML 2026.
- [7] Xu, Y. et al. PACED: Distillation at the Frontier of Student Competence. 2026.
- [8] Lee, C.-H. et al. SEAD: Competence-Aware On-Policy Distillation via Entropy-Guided Supervision. 2026.
- [9] Li, Y. et al. Rethinking On-Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe. 2026.
- [10] Huang, H. and Wei, H. Tail-Aware Top-k On-Policy Distillation. 2026.
- [11] Fu, Z. et al. Rethinking On-Policy Distillation of Large Language Models II: One Training Example. 2026.
- [12] Qwen Team. Qwen3: Think Deeper, Act Faster. 2025.
- [13] Yue, Y. et al. Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?. 2025.
- [14] Liu, Z. et al. ProRL: Prolonged Reinforcement Learning Expands Reasoning Boundaries. 2025.

This version deliberately distinguishes source-supported results, post-hoc analysis, and unresolved limitations. Values without recoverable artifacts are excluded from core quantitative claims.